

1

System wnioskowania Mamdaniego z metodą Wanga-Mendela budowy bazy reguł rozmytych ze zbioru uczącego.

Zbiory uczący i testujący generowane komputerowo. Liczba przesłanek - 2

Cel badań:

1. Określić wpływ liczby podziałów każdej z wielkości wejściowych na jakość systemu wnioskowania (mierzoną błędem średniokwadratowym dla zbioru testującego) – przyjąć liczbę podziałów = 3, 5 i podział równomierny
2. Określić wpływ kształtu funkcji przynależności na jakość systemu wnioskowania (przyjąć funkcje trójkątne, trapezowe, gaussowskie) dla liczby podziałów = 3.
3. Określić wpływ charakteru danych na jakość systemu wnioskowania: dane o rozkładzie równomiernym, dane o 2 skupiskach, dane o 4 skupiskach

Procedura eksperymentu: Wygenerować zbiór 300 obiektów – testować metodą 3-krotnej walidacji krzyżowej. Wyniki uśrednić.

Dane do generowania zbioru obiektów:

Dla punktu 1 i 2 – dane wejściowe o rozkładzie równomiernym na kwadracie $[0,5] \times [0,5]$ 2-wymiarowej przestrzeni wejściowej

Dla punktu 3: Dane jak poprzednio + dane z dwóch (czterech) rozkładów normalnych (ograniczonego do tego samego kwadratu) o różnych wartościach średnich

Przyjąć zależność liniową pomiędzy zmiennymi wejściowymi a zmienną wyjściową

Literatura: Jacek Łęski, Systemy neuronowo-rozmyte, WNT, Warszawa 2008

2

System wnioskowania Mamdaniego z metodą Wanga-Mendela budowy bazy reguł rozmytych ze zbioru uczącego.

Zbiory uczący i testujący generowane komputerowo. Liczba przesłanek - 2

Cel badań:

1. Określić wpływ liczby podziałów każdej z wielkości wejściowych na jakość systemu wnioskowania (mierzoną błędem średniokwadratowym dla zbioru testującego) – przyjąć liczbę podziałów = 3, 5 i podział równomierny
2. Określić wpływ kształtu funkcji przynależności na jakość systemu wnioskowania (przyjąć funkcje trójkątne, trapezowe, gaussowskie) dla liczby podziałów = 3.
3. Określić wpływ charakteru danych na jakość systemu wnioskowania: dane o rozkładzie równomiernym, dane o 2 skupiskach, dane o 5 skupiskach

Procedura eksperymentu: Wygenerować zbiór 400 obiektów – testować metodą 4-krotnej walidacji krzyżowej. Wyniki uśrednić.

Dane do generowania zbioru obiektów:

Dla punktu 1 i 2 – dane wejściowe o rozkładzie równomiernym na kwadracie $[-5,+5] \times [0,10]$ 2-wymiarowej przestrzeni wejściowej

Dla punktu 3: Dane jak poprzednio + dane z dwóch (pięciu) rozkładów normalnych (ograniczonego do tego samego kwadratu) o różnych wartościach średnich

Przyjąć zależność liniową wzg. jednej zmiennej i kwadratową wzg. drugiej zmiennej wejściowej a zmienną wyjściową

Literatura: Jacek Łęski, Systemy neuronowo-rozmyte, WNT, Warszawa 2008

3

System wnioskowania Mamdaniego z metodą Wanga-Mendela budowy bazy reguł rozmytych ze zbioru uczącego.

Zbiory uczący i testujący generowane komputerowo. Liczba przesłanek - 2

Cel badań:

1. Określić wpływ liczby podziałów każdej z wielkości wejściowych na jakość systemu wnioskowania (mierzona błędem średniokwadratowym dla zbioru testującego) – przyjmując liczbę podziałów = 3, 5 i podział równomierny
2. Określić wpływ kształtu funkcji przynależności na jakość systemu wnioskowania (przyjmując funkcje trójkątne, trapezowe, gaussowskie) dla liczby podziałów = 5.
3. Określić wpływ charakteru danych na jakość systemu wnioskowania: dane o rozkładzie równomiernym, dane o 3 skupiskach, dane o 5 skupiskach

Procedura eksperymentu: Wygenerować zbiór 300 obiektów – testować metodą 3-krotnej walidacji krzyżowej. Wyniki uśrednić.

Dane do generowania zbioru obiektów:

Dla punktu 1 i 2 – dane wejściowe o rozkładzie równomiernym na prostokącie $[-2,6] \times [5,10]$ 2-wymiarowej przestrzeni wejściowej

Dla punktu 3: Dane jak poprzednio + dane z trzech (pięciu) rozkładów normalnych (ograniczonego do tego samego prostokąta) o różnych wartościach średnich

Przyjmując zależność kwadratową pomiędzy zmiennymi wejściowymi a zmienną wyjściową

Literatura: Jacek Łęski, Systemy neuronowo-rozmyte, WNT, Warszawa 2008

4

System wnioskowania Mamdaniego z metodą Wanga-Mendela budowy bazy reguł rozmytych ze zbioru uczącego.

Zbiory uczący i testujący generowane komputerowo. Liczba przesłanek - 2

Cel badań:

1. Określić wpływ liczby podziałów każdej z wielkości wejściowych na jakość systemu wnioskowania (mierzona błędem średniokwadratowym dla zbioru testującego) – przyjmując liczbę podziałów = 3, 5 i podział równomierny
2. Określić wpływ kształtu funkcji przynależności na jakość systemu wnioskowania (przyjmując funkcje trójkątne, trapezowe, gaussowskie) dla liczby podziałów = 5.
3. Określić wpływ charakteru danych na jakość systemu wnioskowania: dane o rozkładzie równomiernym, dane o 3 skupiskach, dane o 5 skupiskach

Procedura eksperymentu: Wygenerować zbiór 400 obiektów – testować metodą 4-krotnej walidacji skrośnej. Wyniki uśrednić.

Dane do generowania zbioru obiektów:

Dla punktu 1 i 2 – dane wejściowe o rozkładzie równomiernym na prostokącie $[3,9] \times [-4,0]$ 2-wymiarowej przestrzeni wejściowej

Dla punktu 3: Dane jak poprzednio + dane z trzech (pięciu) rozkładów normalnych (ograniczonego do tego samego prostokąta) o różnych wartościach średnich

Przyjmując zależność kwadratową wzg. jednej zmiennej i liniową wzg. drugiej zmiennej wejściowej a zmienną wyjściową

Literatura: Jacek Łęski, Systemy neuronowo-rozmyte, WNT, Warszawa 2008

5

Rozpoznawanie łańcuchów Markowa I rzędu z algorytmem NN

Cel ćwiczenia:

1. Zbadać wpływ siły zależności pomiędzy stanami łańcucha na jakość klasyfikacji (mierzoną liczbą poprawnie rozpoznanych obiektów testujących)
2. Porównać różne koncepcje algorytmu NN

Procedura eksperymentu: Przyjąć zadanie rozpoznawania z 2 klasami i pojedynczą cechą, założyć łańcuch stacjonarny i jednorodny

Wygenerować zbiór 300 obiektów (cechy, klasa) dla 4 różnych zależności pomiędzy stanami (od braku zależności do zależności deterministycznej)

Przeprowadzić badania metodą 3 krotnej walidacji krzyżowej – wyniki uśrednić

Literatura: Marek Kurzyński, Rozpoznawanie obiektów. Metody statystyczne. Oficyna Wydawnicza Politechniki Wrocławskiej, Wrocław 1997

6

Rozpoznawanie łańcuchów Markowa I rzędu z algorytmem NM

Cel ćwiczenia:

1. Zbadać wpływ siły zależności pomiędzy stanami łańcucha na jakość klasyfikacji (mierzoną liczbą poprawnie rozpoznanych obiektów testujących)
2. Porównać różne koncepcje algorytmu NM

Procedura eksperymentu: Przyjąć zadanie rozpoznawania z 2 klasami i pojedynczą cechą, założyć łańcuch stacjonarny i jednorodny

Wygenerować zbiór 300 obiektów (cechy, klasa) dla 4 różnych zależności pomiędzy stanami (od braku zależności do zależności deterministycznej). Przyjąć normalne rozkłady cechy w klasach o zadanych wartościach średnich i wariancjach

Przeprowadzić badania metodą 3 krotnej walidacji krzyżowej – wyniki uśrednić

Literatura: Marek Kurzyński, Rozpoznawanie obiektów. Metody statystyczne. Oficyna Wydawnicza Politechniki Wrocławskiej, Wrocław 1997

7

Rozpoznawanie łańcuchów Markowa I rzędu z algorytmem k-NN

Cel ćwiczenia:

1. Zbadać wpływ siły zależności pomiędzy stanami łańcucha na jakość klasyfikacji (mierzoną liczbą poprawnie rozpoznanych obiektów testujących)
2. Porównać różne koncepcje algorytmu k-NN i wyniki dla różnych k

Procedura eksperymentu: Przyjąć zadanie rozpoznawania z 2 klasami i pojedynczą cechą, założyć łańcuch stacjonarny i jednorodny

Wygenerować zbiór 300 obiektów (cechy, klasa) dla 4 różnych zależności pomiędzy stanami (od braku zależności do zależności deterministycznej)

Przeprowadzić badania metodą 3 krotnej walidacji skrośnej – wyniki uśrednić

Literatura: Marek Kurzyński, Rozpoznawanie obiektów. Metody statystyczne. Oficyna Wydawnicza Politechniki Wrocławskiej, Wrocław 1997

8

Rozpoznawanie z wykorzystaniem relacji rozmytej

Cel ćwiczenia: Zbadać wpływ dyskretyzacji rozmytej przestrzeni cech na jakość klasyfikacji

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine

Learning Repository (ustalić wybór z prowadzącym), przyjąć zadanie rozpoznawania z 1 cechą i z 2 cechami

Dla zadania z 1 cechą dokonać dyskretyzacji rozmytej dla 3 i 5, 7 wartości słownych, dla zadania z 2 cechami dokonać dyskretyzacji rozmytej dla 3 i 5 wartości słownych.

Wyznaczyć macierz eksperta korzystając z algorytmu genetycznego (z kodowaniem rzeczywistym). Wyznaczyć jakość rozpoznawania metodą 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Literatura: E. Kącki, B. Ostrowska, J. Stempczyńska, Diagnostic Algorithm Based on Expert Matrix Obtained by Monte-Carlo Method, [w:] Computational Intelligence and Applications, P. Szczepaniak [ed.], Physica Verlag, Heidelberg 1999

9

Rozpoznawanie z wykorzystaniem relacji rozmytej

Cel ćwiczenia: Zbadać wpływ dyskretyzacji rozmytej przestrzeni cech na jakość klasyfikacji

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine

Learning Repository (ustalić wybór z prowadzącym), przyjąć zadanie rozpoznawania z 1 cechą i z 2 cechami

Dla zadania z 1 cechą dokonać dyskretyzacji rozmytej dla 3 i 5, 7 wartości słownych, dla zadania z 2 cechami dokonać dyskretyzacji rozmytej dla 3 i 5 wartości słownych.

Wyznaczyć macierz eksperta korzystając z algorytmu genetycznego (z kodowaniem rzeczywistym). Wyznaczyć jakość rozpoznawania metodą 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Literatura: E. Kącki, B. Ostrowska, J. Stempczyńska, Diagnostic Algorithm Based on Expert Matrix Obtained by Monte-Carlo Method, [w:] Computational Intelligence and Applications, P. Szczepaniak [ed.], Physica Verlag, Heidelberg 1999

10

Rozpoznawanie z wykorzystaniem relacji rozmytej

Cel ćwiczenia: Zbadać wpływ dyskretyzacji rozmytej przestrzeni cech na jakość klasyfikacji

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine

Learning Repository (ustalić wybór z prowadzącym), przyjąć zadanie rozpoznawania z 1 cechą i z 2 cechami

Dla zadania z 1 cechą dokonać dyskretyzacji rozmytej dla 3 i 5, 7 wartości słownych, dla zadania z 2 cechami dokonać dyskretyzacji rozmytej dla 3 i 5 wartości słownych.

Wyznaczyć macierz eksperta korzystając z algorytmu genetycznego (z kodowaniem rzeczywistym). Wyznaczyć jakość rozpoznawania metodą 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Literatura: E. Kącki, B. Ostrowska, J. Stempczyńska, Diagnostic Algorithm Based on Expert Matrix Obtained by Monte-Carlo Method, [w:] Computational Intelligence and Applications, P. Szczepaniak [ed.], Physica Verlag, Heidelberg 1999

11

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Przyjąć pulę 20 klasyfikatorów homogenicznych (sztuczne sieci neuronowe). Metoda kombinowania – fuzja na poziomie funkcji klasyfikujących (metoda kombinowania bez uczenia).

Zapewnić dywersyfikację klasyfikatorów bazowych poprzez uczenie na zbiorze losowo wybranych 70% obiektów uczących.

Wyznaczyć jakość rozpoznawania dla 5cio krotnego powtórzenia metody 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Literatura: L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

12

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym).

Przyjąć pulę 6 klasyfikatorów heterogenicznych (NM, 1-NN, 3-NN, 5-NN, ANN z 1 warstwą ukrytą, ANN z 2-warstwami ukrytymi). Metoda kombinowania – fuzja na poziomie funkcji klasyfikujących (metoda kombinowania bez uczenia).

Wyznaczyć jakość rozpoznawania dla 5cio krotnego powtórzenia metody 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Literatura: L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

13

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów.

Przyjąć pulę 20 klasyfikatorów homogenicznych (sztuczne sieci neuronowe). Zapewnić dywersyfikację klasyfikatorów bazowych poprzez uczenie na zbiorze losowo wybranych 70% obiektów uczących.

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej

Wyznaczyć jakość rozpoznawania dla 5cio krotnego powtórzenia metody 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

W każdym punkcie walidacyjnym jest umieszczona źródłowa kompetencja równa 1 (-1) jeśli bazowy klasyfikator prawidłowo (nieprawidłowo) rozpoznał dany obiekt.

Kompetencja w punkcie x jest sumą kompetencji źródłowych mnożonych przez funkcję potencjałową (maleje ze wzrostem odległości punktu walidacyjnego od obiektu rozpoznawanego) – np. gaussowska (wykładnicza).

Literatura: L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

14

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów .

Przyjąć pulę 6 klasyfikatorów heterogenicznych (NM, 1-NN, 3-NN, 5-NN, ANN z 1 warstwą ukrytą, ANN z 2-warstwami ukrytymi).

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej
Wyznaczyć jakość rozpoznawania dla 5cio krotnego powtórzenia metody 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

W każdym punkcie walidacyjnym jest umieszczona źródłowa kompetencja równa 1 (-1) jeśli bazowy klasyfikator prawidłowo (nieprawidłowo) rozpoznał dany obiekt.

Kompetencja w punkcie x jest sumą kompetencji źródłowych mnożonych przez funkcję potencjałową (maleje ze wzrostem odległości punktu walidacyjnego od obiektu rozpoznawanego) – np. gaussowska (wykładnicza).

Literatura: L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

15

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów .

Przyjąć pulę 20 klasyfikatorów homogenicznych (sztuczne sieci neuronowe). Zapewnić dywersyfikację klasyfikatorów bazowych poprzez uczenie na zbiorze losowo wybranych 70% obiektów uczących.

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej
Wyznaczyć jakość rozpoznawania dla 5-cio krotnego powtórzenia metody 2-krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

Pierwsza wersja:

Miarą kompetencji klasyfikatora bazowego w punkcie x jest frakcja poprawnie sklasyfikowanych obiektów walidacyjnych spośród k najbliższych obiektowi x

Druga wersja:

Miarą kompetencji klasyfikatora bazowego w punkcie x jest frakcja poprawnie sklasyfikowanych obiektów walidacyjnych spośród k najbliższych obiektowi x i należących do klasy przypisanych przez oceniany klasyfikator rozpoznawanemu obiektowi x .

Literatura:

L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

K. Woods, W. Kegelmeyer, K. Bowyer, Combination of multiple classifiers using local accuracy estimates, IEEE Trans. on Pattern Analysis and Machine Intelligence 19, 405 – 410 (1997)

16

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów.

Przyjąć pulę 6 klasyfikatorów heterogenicznych (NM, 1-NN, 3-NN, 5-NN, ANN z 1 warstwą ukrytą, ANN z 2-warstwami ukrytymi).

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej

Wyznaczyć jakość rozpoznawania dla 5-cio krotnego powtórzenia metody 2-krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

Pierwsza wersja:

Miarą kompetencji klasyfikatora bazowego w punkcie x jest frakcja poprawnie sklasyfikowanych obiektów walidacyjnych spośród k najbliższych obiektowi x

Druga wersja:

Miarą kompetencji klasyfikatora bazowego w punkcie x jest frakcja poprawnie sklasyfikowanych obiektów walidacyjnych spośród k najbliższych obiektowi x i należących do klasy przypisanych przez oceniany klasyfikator rozpoznawanemu obiektowi x .

Literatura:

L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

K. Woods, W. Kegelmeyer, K. Bowyer, Combination of multiple classifiers using local accuracy estimates, IEEE Trans. on Pattern Analysis and Machine Intelligence 19, 405 – 410 (1997)

17

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów.

Przyjąć pulę 20 klasyfikatorów homogenicznych (sztuczne sieci neuronowe). Zapewnić dywersyfikację klasyfikatorów bazowych poprzez uczenie na zbiorze losowo wybranych 70% obiektów uczących.

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej
Wyznaczyć jakość rozpoznawania dla 5-cio krotnego powtórzenia metody 2-krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

Dla obiektu rozpoznawanego x wyznaczamy zbiór k najbliższych obiektów walidacyjnych
Dla wyznaczonych obiektów walidacyjnych określamy miarę „bliskości” do obiektu rozpoznawanego (dla najbliższego sąsiada miara ta jest równa 1, dla obiektu $(k+1)$ -wszego jest równa 0)

Miarą kompetencji klasyfikatora bazowego jest suma miar „bliskości” obiektów walidacyjnych poprawnie rozpoznanych.

Literatura:

L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

P. C. Smits, Multiple classifier systems for supervised remote sensing image classification based on dynamics classifier selection, IEEE Trans. on Geoscience and Remote Sensing 40, 801 – 813 (2002)

18

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów.

Przyjąć pulę 6 klasyfikatorów heterogenicznych (NM, 1-NN, 3-NN, 5-NN, ANN z 1 warstwą ukrytą, ANN z 2-warstwami ukrytymi).

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej
Wyznaczyć jakość rozpoznawania dla 5cio krotnego powtórzenia metody 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

Dla obiektu rozpoznawanego x wyznaczamy zbiór k najbliższych obiektów walidacyjnych
Dla wyznaczonych obiektów walidacyjnych określamy miarę „bliskości” do obiektu rozpoznawanego (dla najbliższego sąsiada miara ta jest równa 1, dla obiektu $(k+1)$ -wszego jest równa 0)

Miarą kompetencji klasyfikatora bazowego jest suma miar „bliskości” obiektów walidacyjnych poprawnie rozpoznanych.

Literatura:

L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

P. C. Smits, Multiple classifier systems for supervised remote sensing image classification based on dynamics classifier selection, IEEE Trans. on Geoscience and Remote Sensing 40, 801 – 813 (2002)

19

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów.

Przyjąć pulę 20 klasyfikatorów homogenicznych (sztuczne sieci neuronowe). Zapewnić dywersyfikację klasyfikatorów bazowych poprzez uczenie na zbiorze losowo wybranych 70% obiektów uczących.

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej
Wyznaczyć jakość rozpoznawania dla 5cio krotnego powtórzenia metody 2 krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

Dla obiektu rozpoznawanego x i dla jego k najbliższych sąsiadów ze zbioru walidacyjnego wyznaczany jest profil decyzyjny (wektor numerów klas zwróconych przez wszystkie bazowe klasyfikatory).

Wyznaczana jest uśredniona odległość Hamminga profili decyzyjnych k najbliższych obiektów walidacyjnych od profilu obiektu rozpoznawanego – obiekty dla których ta odległość jest mniejsza od przyjętego progu (0.5) stanowią ścisłe otoczenia rozpoznawanego obiektu.

Miara kompetencji klasyfikatora bazowego to częstość poprawnej klasyfikacji dla obiektów ze ścisłego otoczenia.

Literatura: L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

G. Giacinto, F. Roli, Dynamic classifier selection based on multiple classifier behaviour, Pattern Recognition 34, 1879 – 1881 (2001)

20

Rozpoznawanie z wykorzystaniem systemu wieloklasyfikatorowego

Cel ćwiczenia: Porównanie jakości systemu wieloklasyfikatorowego z trenowanym mechanizmem fuzji z pojedynczym klasyfikatorem z puli (metoda SB)

Procedura eksperymentu: Wybrać zbiór danych z bazy benchmarkowej UCI Machine Learning Repository (ustalić wybór z prowadzącym)

Dokonać podziału danych na zbiór testujący i treningowy (losowo, po 50%). Ze zbioru treningowego wydzielić zbiór walidacyjny (losowo 30%). Pozostały zbiór stanowi zbiór uczący do trenowania bazowych klasyfikatorów.

Przyjąć pulę 6 klasyfikatorów heterogenicznych (NM, 1-NN, 3-NN, 5-NN, ANN z 1 warstwą ukrytą, ANN z 2-warstwami ukrytymi).

Metoda kombinowania – ważona fuzja na poziomie funkcji klasyfikujących (metoda kombinowania z uczeniem).

Do wyznaczenia wag poszczególnych klasyfikatorów bazowych (czyli tzw. miar kompetencji bazowych klasyfikatorów) wykorzystać zbiór walidacyjny według metody opisanej poniżej. Wyznaczyć jakość rozpoznawania dla 5-cio krotnego powtórzenia metody 2-krotnej walidacji krzyżowej – wyniki uśrednić.

Metoda wyznaczania miary kompetencji klasyfikatora bazowego:

Dla obiektu rozpoznawanego x i dla jego k najbliższych sąsiadów ze zbioru walidacyjnego wyznaczany jest profil decyzyjny (wektor numerów klas zwróconych przez wszystkie bazowe klasyfikatory).

Wyznaczana jest uśredniona odległość Hamminga profili decyzyjnych k najbliższych obiektów walidacyjnych od profilu obiektu rozpoznawanego – obiekty dla których ta odległość jest mniejsza od przyjętego progu (0.5) stanowią ścisłe otoczenie rozpoznawanego obiektu.

Miara kompetencji klasyfikatora bazowego to częstość poprawnej klasyfikacji dla obiektów ze ścisłego otoczenia.

Literatura: L. Kuncheva, Combining Pattern Classifiers, John Wiley & Sons 2004

G. Giacinto, F. Roli, Dynamic classifier selection based on multiple classifier behaviour, Pattern Recognition 34, 1879 – 1881 (2001)